


(공통논문)RAG_chap1_박채현

RAG 모델 구조



1. **Query Encoder (질문 인코더)**: 사용자의 질문(x)이 들어오면 이를 벡터로 변환
2. **MIPS (Maximum Inner Product Search)**: 변환된 질문과 가장 관련성 높은 문서를 위키피디아 같은 외부 데이터베이스(Document Index)에서 찾기
3. **Generator (생성기-BART)**: 검색된 문서(z)와 원래 질문(x)을 합쳐서 **BART** 같은 생성 모델에 넣음. → 답변을 생각
4. **Marginalize (확률 통합)**: 검색된 여러 문서들을 봤을때 그 답변이 나올 확률을 싹 다 더해서 가장 정답일 확률이 높은 문장을 선택, 답변(y)을 생성

BART-페이스북(현 Meta)이 만든 글쓰기에 특화된 인공지능 모델

2. Methodology: RAG는 어떻게 문장을 만들어낼까

RAG 모델이 문장을 생성하는 방법은 크게 두 가지 방식(Sequence와 Token).

- x : 사용자의 입력 질문 (Input query)
- z : 검색기가 찾아온 외부 문서 (Retrieved document)
- y : 생성기가 만들어낸 최종 답변 (Generated text)

2.1 RAG-Sequence Model

RAG-Sequence 모델은 '생성하려는 전체 답변(y)이 하나의 같은 문서(z)에서 파생되었다'고 가정하는 방식. 쉽게 말해, 참고할 책을 하나 딱 고르면, 그 책 한 권의 맥락만 유지하면서 답변을 처음부터 끝까지 쭉 써 내려가는 방식

$$p_{\text{RAG-Sequence}}(y|x) \approx \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) p_\theta(y|x, z) = \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) \prod_i p_\theta(y_i|x, z, y_{1:i-1})$$

$$\prod_i^N p_{\theta}(y_i|x, z, y_{1:i-1})$$

하나의 문서(z)를 정해놓고, 첫 단어부터 끝 단어까지 쪽 생성할 확률을 곱함. 즉, 답변 생성 도중에는 문서를 바꾸지 않음

$$= \sum_{z \in \text{top-}k(p(\cdot|x))} p_{\eta}(z|x)$$

다음에 "문서 A로 썼을 때 확률", "문서 B로 썼을 때 확률".등 모두 더함(Marginalize).

2. RAG-Token Model

답변의 각 단어(Token)를 생성할 때마다 다른 문서를 참고할 수 있음

$$p_{\text{RAG-Token}}(y|x) \approx \prod_i^N \sum_{z \in \text{top-}k(p(\cdot|x))} p_{\eta}(z|x) p_{\theta}(y_i|x, z, y_{1:i-1})$$

여기서는 **합이 안쪽에** 있음. 즉, **단어 하나를 만들 때마다** 모든 상위 K개 문서의 확률을 다 합쳐서 고려함.

그렇게 단어마다 계산된 확률들을 쪽 곱해나감.